# Homework4

孝俊森 202120709

- 写一个C表达式,在下列描述的条件下产生1,其他情况产生0, 假设X是int类型。代码中不能使用==或! =进行测试。
  - x的任何位都等于1;
  - x的任何位都等于0;
  - x的最低有效字节中的位都等于1;
  - x的最高有效字节中的位都等于1;

- A. !(~x)
- B. !x
- C. !~(x | 0x00ffffff)
- D. !(x & 0x000000ff)

- int为32位, float和double分别是32位和64位IEEE格式
  - Int x =random();
  - Int y = random();
  - Int z = random();
  - Double dx = (double)x;
  - Double dy = (double)y;
  - Double dz = (double)z;
- 对于下面的每个C表达式,判断是否恒为1。如果是请说明原理,如果不是请举出反例。
  - A. (float)x == (float)dx
  - B. dx-dy == (double)(x-y)
  - C. (dx+dy)+dz == dx+(dy+dz)
  - D. (dx\*dy)\*dz == dx\*(dy\*dz)
  - E. dx/dx == dz/dz

A. (float)x == (float)dx

不成立。比如x为int的最大值时,超过float的精度。

• B. dx-dy == (double)(x-y)

不成立。当x-y发生溢出时等式不成立,如x=Tmin, y=1, x-y发生下溢。

• C. (dx+dy)+dz == dx+(dy+dz)

成立。dx,dy,dz是由整型x,y,z转换而来的,相加不会超过double的精度,因此不会产生舍入的误差,满足加法结合律。

D. (dx \* dy) \* dz == dx \* (dy \* dz)

**不成立**。double无法精确表示 $2^{64}$ 以内所有数,三个数相乘可能会产生舍入,因此不满足乘法结合律。例如取 x=0xe87d0982,y=0xd2027960,z=0xd119203f,可以验证等式不成立。

• E. dx/dx == dz/dz

**不成立**。dx或dz为零时不成立。

- 编写如下函数,求浮点数f的绝对值|f|。如果f是NaN,那么应该直接返回f(注意NaN不要对f做任何修改)。
- 其中float\_bits等价于unsigned,是float数字的二进制形式
  - typedef unsigned float\_bits;
- /\* Compute |f|. If f is NaN, then return f. \*/
- float\_bits float\_absval (float\_bits f);

```
float_bits float_absval(float_bits f)
{
    unsigned abs = f&(0x7FFFFFFFF);//符号位取0
    if (abs>(0x7F800000)) return f;//判断NAN
    return abs;//否则输出绝对值
}
```

- •实现如下函数,对于浮点数f,计算2.0\*f。如果f是NaN,你的函数应该简单返回f。
- /\* Compute 2\*f. If f is NaN, return f. \*/
- float\_bits float\_twice(float\_bits f);

#### 基本思路

- 若浮点数为规格化数的时候, 只需要阶码 + 1。
  - 。特殊情况: 当e的为11111110,此时不可以直接+1,它们\*2会溢出,因此要提升为无穷。
- 若浮点数为非规格化数, ×2就相当于把后面的小数左移一位。

```
float bits float twice(float bits f) {
   unsigned s = f >> 31;//符号位
   unsigned exp = f >> 23 & 0xFF;//阶码
   unsigned frac = f & 0x7FFFFF;//尾数
   int is_NAN_or_infinity = (exp == 0xFF);//判断是否是无穷或者NAN,即阶码为11111111
   if (is NAN or infinity) return f;
   //非规格化数
   if (exp == 0) frac <<= 1;
   //最大的特殊规格化数,*2溢出,要提升为无穷
   else if (exp == 0xFE){
      exp = 0xFF;
      frac = 0;
   //规格化数
   else exp += 1;
   return sig << 31 | exp << 23 | frac;
```